

**基於 DE-MRBFNN 與 NSGA3 之新式資料中心冷卻系統節能優化**  
**Energy Saving Optimization of Cooling System for New Type Data Center**  
**Based on DE-MRBFNN and NSGA3**

許應良<sup>1\*</sup>、陳金聖<sup>2</sup>  
Ying-Liang Hsu<sup>1\*</sup>, Chin-Sheng Chen<sup>2</sup>

<sup>1\*,2</sup> 國立臺北科技大學自動化科技研究所

<sup>1\*,2</sup> Graduate Institute of Automation Technology, National Taipei University of Technology,  
Taipei City, Taiwan, R.O.C.

**摘要**

近年網際網路爆炸式的成長使資料中心需求量增高，資料中心節能(Data Center Power Conservation)議題在現今備受重視，這會帶給經營企業、發電廠及環境莫大的助益，而找出最佳冷卻系統操作點能降低冷卻系統能源消耗以及提升機櫃進風口溫度一致性。有鑑於國內鮮少針對新式資料中心節能提供數據集及進行節能優化程序的研究，為此本文提出兩點新穎作法：第一點，我們提出差分進化演算法結合混合放射狀基底函數網路方法(DE-MRBFNN)增加神經元多樣性，以此在少量資料集狀況下訓練並擬合出最佳模型的架構，並藉由此法預測模擬場域上的熵增，在實際場域上則預測電源使用效率(PUE)與機櫃進風口散佈溫度，由此法解決熱流模型及實際場域實驗耗時問題。第二點，我們提出透過 DE-MRBFNN 與 DE-RBFNN 的稀疏網路模型預測結果回饋在多目標基因演算法 NSGA3 上的一套最佳化程序，以此多目標狀況下快速求取最佳解。實驗結果表明本論文所提出的程序在模擬的節能任務上能達到可用能損耗下降 9.2%(43.68kW)，而在實際場域的節能任務上能達到 PUE 下降 7.0%(1.33)。

關鍵字詞：資料中心、節能、混合放射狀基底函數網路、最佳化演算法、多目標優化、基因演算法、差分進化演算法

#### Abstract

In recent years, the explosive growth of the Internet has increased the demand for data centers. Data Center Power Conservation is a critical issue. This will bring great benefits to operating companies, power plants, and the environment. Finding the best system operation point can reduce cooling system energy consumption and improve server inlet temperature consistency. Since there are few domestic kinds of research on providing data sets and energy-saving optimization procedures for the energy-saving of new type data centers, this article proposes two novel approaches: First, we propose a differential evolution algorithm combined with a mixture of radial basis function network(DE-MRBFNN) to increase the diversity of neuron, so as to train and fit the best model architecture under the condition of a small number of data sets, and then use this method to predict the entropy increase in the simulation field, and the power usage efficiency (PUE) and the air inlet distribution temperature of the cabinet in the actual field, this method solves the time-consuming problems corresponding to computational fluid dynamics model and the actual field, respectively. Second, we propose a set of optimization procedures that feedback the prediction results of the sparse network model of DE-MRBFNN and DE-RBFNN to the multi-target genetic algorithm NSGA3, so as to quickly get the optimal solution under multi-objective conditions. The experimental results show that the method proposed in this thesis can reduce the exergy destruction by 9.2%(43.68kW) in the simulation field, and can reduce the PUE by 7.0%(1.33) in the actual field.

Keywords: Data Center, Energy Conservation, Mixture Radial Basis Function Network, Optimization Algorithm, Multi-objective Optimization, Genetic Algorithm, Differential Evolution Algorithm

## 一、前言

資料中心(Data Center, DC)是全球網路運作的一項重要設施，其提供加速、計算、儲存、展示與傳遞功能，在早期因操作與維護複雜常常僅應用於軍事目的其數量十分稀少，在電腦普及後使網際網路以及雲端服務中資訊傳遞、儲存、計算需求增加，使資料中心數量持續增高[1][2]。因應大量資訊的控制方式開始複雜，資料中心採用分層設計與新網路電纜標準並且被公認為標準型式流傳。另一方面，隨著系統的標準化、模組化，分為 IT 設備(例:CPU、UPS)、冷卻系統(例:CRAC)、基礎設施(例:空調、通風、照明設備)，資料中心規模迅速擴大但同時加劇能源耗損問題如圖 1 所示。




圖 1.電力需求預測與歷史比較橫條圖[1]

近期人工智慧演算法進展，其分支最佳化演算法與深度學習獲得了重要的突破，因此在開發及商用的案例漸多，在資料中心領域上對於預測與優化資料中心的演算法架構研究也開始被受重視。在 2013 年，Zhihang Song 提出了基於基因演算法與神經網路進行資料中心的風量與熱分布最佳化方法[3]，接著 2014 年 Google 公司利用五層神經網路對資料中心全場域建立感測器資訊進行訓練並應用於實際預測上取得了高度的準確度[4]，此屬資料中心運用人工智慧的里程碑，在此往後許多有關深度學習與最佳化應用更多在資料中心領域上。

如圖 2 所示，在資料中心耗能成分中冷卻占比最高，為了達成降低能源使用的目標，本文將採用新式架構資料中心，並

針對資料中心的最佳化設計著手，另一方面，因應新架構資料中心與高架地板資料中心物理設計上之不同，需再重新設計最佳化的決策參數與目標參數，並將其定義為一種多目標問題，來控制決策參數以期望減低冷卻設備消耗的能源。




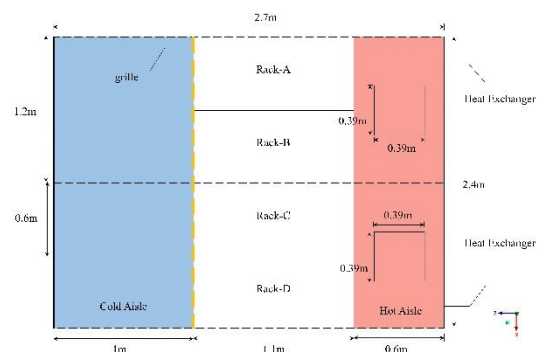
圖 2.資料中心耗能成分圓餅圖[5]

## 二、資料中心冷卻節能方法

此章節將介紹資料中心之物理架構、資料集、最佳化演算法及深度學習預測架構。

### 2.1 物理架構

該新式資料中心形式為直鏈式機櫃配置[6]，配置情形如圖 3(a)，由四個機櫃，每櫃五個伺服器組成，並在冷風道與熱風道之間進行密封作業完整隔離。在機櫃、冷風道與熱風道之上為熱交換器，冷風道進風口為全開放式，熱風道出風口為兩個正方開孔。如圖 3(b)所示，伺服器內部以包覆螺旋式鰭片的六根發熱銅管替代真實發熱源，後端以軸流扇協助抽風維持流場。



(a)

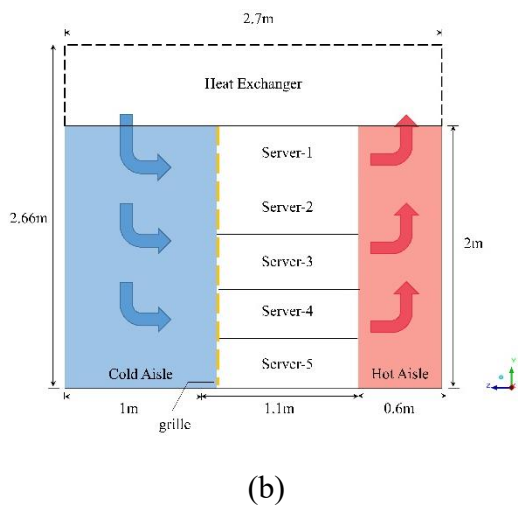


圖 3.資料中心場域架構尺寸圖  
(a)直鏈式上視圖 (b)直鏈式側視圖

## 2.2 資料集

本資料集為驗證模擬與實際場域是否皆適用本方法因此將其分為兩種資料集進行模型訓練，模擬資料集採用計算流體動力學模擬軟體 Ansys fluent 的模擬資料，實際場域資料集利用風速、溫度感測器量測進行蒐集。如圖 4 所示，該新式資料中心會取得資料的連接口為熱交換器供風口、熱交換器迴風口、機櫃進風口與機櫃出風口。如圖 5 所示，其為控制參數在設定在特定區間，分別為模擬之熱交換器供風溫度 18~27°C 與熱交換器溫差 5~11°C，實際場域之機櫃平均進風溫度 18~27°C 與質量流率 2.8~4.1kg/s，並將伺服器設定為全載狀態發熱量。





圖 4.新式資料中心各連接口示意圖



(a) 模擬資料集 (b) 實際場域資料集  
圖 5.資料集控制參數分布圖

## 2.3 預測架構

(1)DNN[7]:由多層感知機(MLP)推廣至多隱藏層之架構，適合用於擬合非線性系統，該神經元由公式(5)表示。

$$f_n = \sigma(W_n \cdot x + b_n) \quad (5)$$

其中 $f_n$ 為神經元輸出、 $W_n$ 為權重、 $b_n$ 為偏差、 $x$ 為神經元輸入、 $\sigma$ 為激勵函數。

(2)RBFNN[8]:該模型由一層線性輸入層、一層隱藏層及一層線性輸出層組成，隱藏層中放射狀基底函數為一個取值僅依賴於原點距離的實數函數，藉由增加神經元的數量可以逼近任意函數。

(3)MRBFNN:本文提出 MRBFNN 模型架構，由 RBFNN 延伸而成，同樣具有一層線性輸入層、一層隱藏層及一層線性輸出層，如圖 6 所示，在一般情況下 RBFNN 的隱藏層皆為相同的放射狀基底函數組成，而此處被修改為多種放射狀基底函數共同組成，該改動可更好擬合不同情境產生的輸入與輸出對應關係。




圖 6. 混合放射狀基底函數網路架構圖

## 2.4 最佳化演算法

### (1)SGA[9]:

於 1989 年 Goldberg 提出，其會於初始時生成一個群體，在進化過程中染色體會發生選擇(Selection)、交配(Crossover)與突變(Mutation)，藉此產生下一代新染色體在之後的評價過程利用適應度函數(Fitness Function)進行比分，經由特定條件判斷是否達到來結束整個搜尋過程並給予最佳解。

### (2)DE[10]:

於 1997 年由 Storn 與 Price 在基因演算法進化思想的基礎上提出，對於差分進化算法與簡單基因演算法相同點都是隨機初始化群體，並以每個個體的適應度為選擇標準，主要程序也都包括選擇、交配與突變三個步驟，不同之處是差分進化演算法以差分向量做為基礎進行突變與交配的演算法。

(3)NSGA2[11]:該多目標最佳化演算法由 NSGA 改良而成，添加了菁英政策與擁擠度概念並設計快速非支配排序將原有的非支配排序時間複雜度從 $O(MN^3)$ 縮減成 $O(MN^2)$ ，新添加的擁擠度算法會藉由會將在目標空間過於密集的部分刪減至與初始個體數相等的狀況，經由迭代後可以在每次得出的解中保留在目標空間過於稀

疏的部分，從而使種族多樣性保持的狀況下能保持收斂。

(4)NSGA3[12]:該多目標最佳化演算法由 NSGA2 改良而成，同樣都是改變選擇子代的方法，該算法將擁擠距離改為參考點距離，該方法提供了系統性的選擇方式，並且提高了在高維目標時的收斂速度及多樣性。

## 2.5 最佳化模型架構

為確定模型內需要多少的神經元以及何種放射狀基底函數核才夠使精度提高，為此我們將設定兩種最佳話架構流程，如圖 7 所示，該最佳化採用 GA 及 DE 兩種方法並將其中的評估指標改由模型的評估指標 MSE 來取代原有的評估方式，該方法可以明確地使演算法往 MSE 更低的方向進行收斂，以此來達成在數據量不足的情況下建構出最有效的模型。

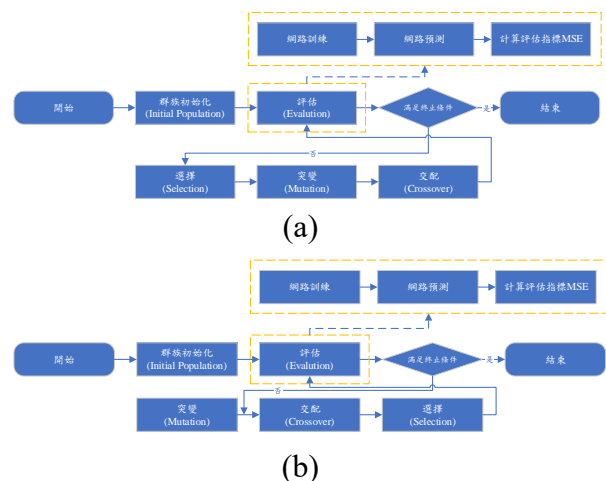


圖 7.最佳化架構流程圖

(a)GA 架構 (b)DE 架構

## 2.6 新式資料中心節能優化流程

本文中最主要解決的問題為冷卻設備耗電問題，該問題可轉換為一種多目標問



題，並且作為優化流程的系統最佳化部分。該優化流程將會先經過資料的預處理，透過網路模型尋找最佳結構並訓練網路模型，在獲得已訓練的模型後進行推理並藉由多目標最佳化演算法來求取操作系統最佳解，並依據重要性來取唯一解，在最終會使用 CFD 模擬以及實驗來驗證該流程的可用性。

### 三、結論

對於將前述的預測架構及最佳化演算法將應用於本次兩種實驗中，其一為模型的特性比較，另一個為系統最佳化的比較，並且該實驗將會重複執行10次取平均值。如表1所示，在少量資料集下進行訓練後，在DE架構下比起SGA架構能夠在有些神經元的狀況下取得更低的MSE，而在DE架構下的模型中MRBFNN表現出可以使用最低的神經元數量，而RBFNN則是獲得更好的MSE，因此將該兩模型作為系統最佳化階段的推理模型。

表 1.模型特性實驗表

最佳化架構	DE			SGA		
模型架構	MRBFNN	RBFNN	NN	MRBFNN	RBFNN	NN
模擬						
平均 MSE	0.439	0.208	0.851	1.496	0.526	11.966
平均數量	5230.9	6423.8	6435.7	5085.5	5349.9	5868.7
實際場域						
平均 MSE	0.148	0.080	0.140	0.144	0.100	22.762
平均數量	4806.7	5743.8	6900.2	4922.5	5462.2	5692.9

在系統最佳化的環節中，將會利用 NSGA2以及NSGA3進行多目標最佳化任務。如表2所示，該模擬環境上之實驗藉由冷通道、熱通道及熱交換器之總和可用能損失可以發現，在未經優化前的表現可用能損失偏高至48.31，對於經過最佳化後基本上都可以降低至43.9達到節能的目的，而不論在採用本文中何種多目標最佳化演

算法及模型進行搭配，其效果幾乎一致，僅有微小的差異。如表3所示，該實際場域上之實驗藉由測量各部位的耗功來獲得能源使用效率，並於表中可以發現與表1相同的特性在多目標最佳化演算法部分 NSGA3與NSGA2幾乎都能找到一致的解，並且也起到顯著的節能效果。

表2.模擬系統最佳化實驗表

最佳化方法_建模方式	熱交換器平均供風溫度/熱交換器供風及目標三迴風溫度差	可用能損失
未最佳化_實際場域	18°C/5°C	48.31
NSGA2_DE-MRBFNN	22.71°C/9.27°C	43.92
NSGA2_DE-RBFNN	22.42°C/9.57°C	43.86
NSGA3_DE-MRBFNN	22.73°C/9.26°C	43.88
NSGA3_DE-RBFNN	22.36°C/9.63°C	43.87

表 3.實際場域系統最佳化實驗表

最佳化方法_建模方式	機櫃平均進風溫度/熱交換器質量流率	能源使用效率
未最佳化_實際場域	18°C/4.100 <sup>kg</sup> /s	1.43
NSGA2_DE-MRBFNN	22.43°C/2.800 <sup>kg</sup> /s	1.33
NSGA2_DE-RBFNN	26.99°C/3.605 <sup>kg</sup> /s	1.39
NSGA3_DE-MRBFNN	22.40°C/2.800 <sup>kg</sup> /s	1.33
NSGA3_DE-RBFNN	26.99°C/3.605 <sup>kg</sup> /s	1.39

### 四、討論

對於現階段研究解邁向一個最佳化流程快速應用的可能，其只需要少量的資料即可完成對最佳化操作參數的獲取，對於現實層面中會遇到不定負載的問題則無列入討論，而對此利用 LSTM 網路來達成預測負載的問題，並且搭配本文最佳化架構來進行是未來可嘗試的目標，並且利用線上式可以避免線下式需要蒐集資料的時間，來進行持續性訓練，在有些負載的問題中或許能夠自主修正隨人們生活習慣及資料中心系統變化而產生的差異，來確保該最佳化的操作參數一直符合當下的環境，並達成降低能源消耗的願景。

## 五、參考文獻

1. E. Masanet, A. Shehabi, N. Lei, S. Smith, and J. Koomey, "Recalibrating Global Data Center Energy-Use Estimates," *Science*, vol. 367, Issue 6481, pp. 984-986, Feb. 2020, doi: 10.1126/SCIENCE.ABA3758
2. S. Mittal, "Power management techniques for data centers: A survey," arXiv preprint arXiv:1404.6681, 2014.
3. Z. Song, B. T. Murray, and B. Sammakia, "Airflow and Temperature Distribution Optimization in Data Centers Using Artificial Neural Networks," *International Journal of Heat and Mass Transfer*, vol. 64, pp. 80-90, 2013, issn: 0017-9310.
4. J. Gao, "Machine Learning Applications for Data Center Optimization," Google White Paper, 2014.
5. M. Dayarathna, Y. Wen, and R. Fan, "Data Center Energy Consumption Modeling: a Survey," *IEEE Communications Surveys & Tutorials*, vol. 18, no. 1, pp. 732-794, Firstquarter 2016, doi: 10.1109/COMST.2015.2481183.
6. 林靖婕、施陽正、江品翰、楊杰恩、趙楚源, "新世代資料中心數值模擬分析", 能源與冷凍空調學術暨技術研討會(ERAC), 臺中, 2020 年 10 月。
7. Y. Bengio, "Learning deep architectures for AI," *Foundations and Trends in Machine Learning*, 2009.
8. D. S. Broomhead, and D. Lowe, "Radial basis functions, multi-variable functional interpolation and adaptive networks," Royal Signals and Radar Establishment, Malvern United Kingdom, 1988.
9. D. E. Goldberg, "Genetic Algorithms in Search, Optimization and Machine Learning," Oct. 1989.
10. R. Storn, K. Price, "Differential Evolution – A Simple and Efficient Heuristic for global Optimization over Continuous Spaces. *Journal of Global Optimization*," vol. 11, pp. 341-359, Dec. 1997, doi: 10.1023/A:1008202821328.
11. K. Deb, A. Pratap, S. Agarwal and T. Meyarivan, "A fast and elitist multiobjective genetic algorithm: NSGA-II," *IEEE Transactions on Evolutionary Computation*, vol. 6, no. 2, pp. 182-197, April 2002, doi: 10.1109/4235.996017.
12. K. Deb and H. Jain, "An Evolutionary Many-Objective Optimization Algorithm Using Reference-Point-Based Nondominated Sorting Approach, Part I: Solving Problems With Box Constraints," *IEEE Transactions on Evolutionary Computation*, vol. 18, no. 4, pp. 577-601, Aug. 2014, doi: 10.1109/TEVC.2013.2281535.